

Return-Sharpe Aware Ranking with Multi-Model RRF Fusion

A PREPRINT

摘要

量化投资的核心挑战在于如何从海量金融数据中筛选出具有超额收益潜力的资产并构建稳健的投资组合。传统多因子模型依赖人工因子构建和线性组合，难以捕捉复杂的非线性交互；而深度学习方法虽具强大拟合能力，但在金融低信噪比环境下易过拟合，训练成本高且可解释性差。排序学习（Learning to Rank, LTR）作为一种兼顾表达能力与可解释性的中间路线，已在信息检索领域取得显著成功，但其在量化选股中的应用仍面临损失函数与投资目标不对齐、单模型预测不稳定等关键问题。

本文提出一种面向 A 股市场的量化选股框架，包含三个核心创新：（1）收益-夏普感知排序损失函数，通过收益加权、夏普惩罚和 CVaR 约束将投资目标嵌入排序学习过程；（2）多模型排序融合策略，利用 Reciprocal Rank Fusion (RRF) 整合 LightGBM 与 XGBoost 的排序优势；（3）面向用户的 LLM 自然语言推荐，将专业模型输出转化为普通投资者可操作的投资建议。

实验设计四组对比：测试标准 NDCG、收益加权 NDCG、收益加权 + 夏普惩罚及收益加权 + 夏普惩罚 + CVaR 四种损失函数，验证收益-夏普感知损失的有效性；对比分数平均、RRF、Stacking 及加权 RRF 四种融合策略，证明 RRF 融合的优越性；测试纯模型输出与 LLM 增强解释方案，验证 AI 解读的实用价值；系统对比 Pointwise、Pairwise、Listwise 及本文方法的综合表现。实验中包含基线对比和消融实验，以验证各创新组件的独立贡献。基于近 10 年约 3000 只 A 股周频数据的实证研究表明，基线 LightGBM 年化收益率达到 16.55%，夏普比率为 0.711；E1c 损失函数（收益加权 + 夏普惩罚 + CVaR 约束，vol_penalty=0.5）夏普比率达到 0.720，最大回撤降至 12.97%；分数平均融合（E2a）夏普比率达到 0.727，为所有方法中最高。消融实验验证了三个创新组件的有效性，场景分析表明该方法在各类市场环境中均表现稳健。

这项研究贡献了一个面向 A 股市场的收益感知排序损失与多模型融合的综合基准，揭示了不同损失函数设计和融合策略如何影响模型学习横截面和时间模式的能力。通过阐明损失函数选择、模型融合与投资组合性能之间的关系，本研究为开发更有效的量化金融深度学习模型提供了更清晰的方向。

1 Experiment Preparation

1.1 Data Description

数据来源与样本划分：本实验使用近 10 年 A 股市场周频数据作为研究样本，从 2016 年 1 月到 2026 年 X 月，涵盖约 X000 只 A 股上市公司。

特征与标签：按照时间顺序将数据集划分为训练集、验证集和测试集三部分。数据集划分严格遵循时间顺序，避免未来信息泄露，确保实验结果的可靠性。（训练集，占总体数据的 70%，用

于模型参数学习；验证集，占总体数据的 15%，用于超参数调优和早停策略；测试集，占总体数据的 15%，用于最终模型性能评估。）

测试集包含 225,562 条记录，103 个查询截面（周），34 个特征因子。

2 Experiment

2.1 收益-夏普感知损失函数对比

标准 LambdaRank 损失函数通过优化 NDCG 指标来提升排序质量，其核心思想是使模型输出的排序与真实收益排序尽可能一致。然而，从投资组合管理的角度看，排序准确性并非唯一目标——投资决策的核心是判断选入 Top-K 组合的股票能否带来较高的收益和风险调整能力。标准 NDCG 在实盘中存在两个局限性：收益权重缺失。它对高收益股票和低收益股票给予相同的排序权重，不能区分不同收益水平的股票对投资组合的贡献差异；风险考量不足。未考虑股票的波动率特征，可能导致选入高收益但高波动的股票，从而降低投资组合的夏普比率。

针对上述问题，本实验设计了改进标签的构造方法，逐步将投资目标嵌入排序学习过程。

2.1.1 实验原理

本文设计了四种不同的排序损失函数，用于对比不同目标函数对选股策略绩效的影响，具体形式如下：

1. 标准 NDCG 损失 (Baseline)

标准 NDCG 损失仅优化排序质量，不考虑收益与风险特征，其数学形式为：

$$L_{\text{rank}} = -\frac{1}{|D_q|} \sum_{k=1}^K \frac{2^{\text{rel}_k} - 1}{\log(k+1)} \quad (1)$$

其中 rel_k 为离散相关性标签（取值范围为 0-30 的整数）。

2. 收益加权 NDCG 损失 (E1a)

在标准排名标签基础上，根据实际收益率大小额外提升高收益股票的权重，引导模型更侧重将高收益股票排在 Top-K 区间。增益函数定义为：

$$g(r_k) = |r_k|^\alpha \cdot \text{sign}(r_k) \quad (2)$$

其中 r_k 为第 k 只股票的未来一周收益率， α 为收益敏感度参数，本文默认设置 $\alpha = 1.0$ 。对应损失函数为：

$$L_{\text{return}} = -\frac{1}{|D_q|} \sum_{k=1}^K \frac{g(r_k)}{\log(k+1)} \quad (3)$$

3. 收益加权 + 夏普惩罚 (E1b)

在 E1a 基础上引入波动率惩罚项，降低高波动股票的权重，目标是提升组合的风险调整后收益。夏普惩罚项定义为：

$$L_{\text{sharpe}} = L_{\text{return}} + \lambda \cdot \max(0, -\text{Sharpe}_{\text{TopK}}) \quad (4)$$

其中 $\text{Sharpe}_{\text{TopK}}$ 为 Top-K 组合的滚动夏普比率， λ 为惩罚系数，本文默认设置 $\lambda = 0.5$ 。

4. 收益加权 + 夏普惩罚 + CVaR 约束 (E1c)

在 E1b 基础上进一步引入条件风险价值 (CVaR) 约束, 对极端亏损风险进行额外惩罚, 避免策略选入可能发生极端亏损的股票。CVaR 约束项定义为:

$$L_{\text{cvar}} = L_{\text{sharpe}} + \gamma \cdot \text{CVaR}_{\alpha}(\text{TopK}) \quad (5)$$

其中 CVaR_{α} 为 Top-K 组合在置信水平 α 下的条件风险价值, 本文默认设置 $\alpha = 0.90$; γ 为风险厌恶系数, 本文默认设置 $\gamma = 0.3$ 。

2.1.2 实验过程

1. 模型训练

采用 LightGBM 作为基础模型, 设置五组对比实验:

表 1: 实验 1: 实验组设计

组别	损失函数	说明
B-LGBM	标准 LambdaRank (NDCG)	LightGBM 默认 lambdarank 目标
B-XGB	标准 rank:ndcg	XGBoost 默认 rank:ndcg 目标
E1a	收益加权 NDCG	增益函数替换为连续收益率加权
E1b	收益加权 NDCG + 夏普惩罚	加入 Top-K 组合夏普比率惩罚项
E1c	收益加权 NDCG + 夏普惩罚 + CVaR	加入条件风险价值约束

训练参数设置: 实验组 early stopping rounds = 150, 学习率 0.01–0.1, 正则化 0.03–0.2。

2. 核心代码实现

本研究实现了三个层次递进的标签构造函数, 以增强模型对风险调整后收益的学习能力:

- 第一层为 `return_aware_relevance` (对应实验组 E1a): 在标准排名标签基础上, 根据实际收益率大小动态提升高收益股票的标签值, 引导模型更关注具有超额收益潜力的资产。
- 第二层为 `sharpe_aware_relevance` (对应实验组 E1b): 在 E1a 基础上引入波动率惩罚机制, 通过夏普惩罚系数 (本文设置为 0.5) 对高波动股票的标签进行调整, 引导模型平衡收益与风险。
- 第三层为 `cvar_aware_relevance` (对应实验组 E1c): 在 E1b 基础上加入 CVaR (条件风险价值) 惩罚项, 在置信水平为 0.10 下对左尾极端收益股票施加额外惩罚 (惩罚系数设置为 0.3), 增强模型对下行风险的敏感性。

为支持灵活的标签策略实验, 本研究实现了 `train_final_lightgbm_with_label_fn` 函数作为统一训练入口, 允许传入任意自定义标签构造函数完成模型训练。

2.1.3 实验结果

1. 排序质量对比

2. 回测指标对比 (最优 `vol_penalty` 配置)

3. `vol_penalty` 参数敏感性分析

表 2: 实验 1: 排序质量对比 (NDCG)

方法	NDCG@5	NDCG@10	NDCG@20	MAP
B-LGBM (基线)	0.1894	0.1629	0.1452	0.3056
E1a (收益加权)	0.2346	0.2071	0.1872	—
E1b (收益 + 夏普)	0.1641	0.1553	0.1452	—
E1c (收益 + 夏普 + CVaR)	0.1638	0.1552	0.1415	—
参考: <i>XGBoost</i> 基线				
B-XGB (基线)	0.3782	0.3621	0.3577	0.3311

表 3: 实验 1: 回测指标对比 (最优 vol_penalty 配置)

方法	vol_pen.	年化收益 (%)	夏普	最大回撤 (%)	换手率	胜率 (%)
B-LGBM	1.0	16.55	0.711	16.37	1.030	48.5
E1a-LGBM	0.7	13.27	0.602	14.48	0.894	49.5
E1b-LGBM	0.7	13.97	0.636	11.28	1.117	48.5
E1c-LGBM	0.5	15.15	0.720	12.97	0.933	50.5




图 1: 实验 1: Sharpe Ratio vs. vol_penalty

2.2 多模型排序融合对比

单模型预测存在系统性偏差。金融时间序列具有高度噪声、非平稳性和 regime switching 等特征，不同模型对数据生成过程的假设不同，其预测误差在不同时期和不同市场状态下呈现异质性，使得单一模型难以在所有市场环境下保持稳定表现，而简单模型平均又无法充分利用各模型的优势。为解决上述预测稳定性不足和排序尺度差异的问题，本实验设计了四种多模型融合策略，通过排序级融合提升选股稳定性。

2.2.1 实验原理

1. 分数平均融合 (E2a)

将多个模型的预测分数归一化后取平均，生成融合排序，核心思想是通过平均降低单模型预测方差，但依赖于分数归一化处理。融合分数计算公式如下：

$$s_{\text{fusion}} = \frac{1}{M} \sum_{m=1}^M \text{norm}(s_m) \quad (6)$$

其中 s_m 为模型 m 的预测分数， $\text{norm}(\cdot)$ 为归一化函数， M 为模型数量。

2. RRF 融合 (E2b)

Reciprocal Rank Fusion (RRF) 仅使用排名位置进行融合，对模型输出尺度差异天然鲁棒，核心思想是排名比分数更稳定，且无需归一化处理。RRF 分数计算公式如下：

$$\text{RRF}(d) = \sum_{m \in M} \frac{1}{k + \text{rank}_m(d)} \quad (7)$$

其中 $\text{rank}_m(d)$ 为股票 d 在模型 m 中的排名， k 为平滑常数（默认设置为 60）。该公式的特点是：排名越靠前（rank 越小），RRF 分数越高， k 值控制高排名股票的区分度。

3. Stacking 融合 (E2c)

使用 Ridge 元学习器在验证集上学习最优融合权重，核心思想是通过元学习器自动学习各模型的最优组合权重，而非简单平均。采用两层架构设计：

- 第一层：LightGBM 预测分数 + XGBoost 预测分数（作为元特征）
- 第二层：Ridge 回归（ $\alpha = 1.0$ ）作为元学习器
- 训练方式：时序滚动交叉验证（避免未来信息泄露）

4. 加权 RRF 融合 (E2d)

根据验证集 NDCG@10 为各模型分配权重，高 NDCG 模型获得更大权重，核心思想是模型性能越好，其在融合中的话语权越大。加权 RRF 分数计算公式如下：

$$\text{RRF}_{\text{weighted}}(d) = \sum_{m \in M} \frac{w_m}{k + \text{rank}_m(d)} \quad (8)$$

其中 w_m 为模型 m 的权重，根据验证集 NDCG@10 动态调整： $w_m = \text{NDCG}_m / \sum_j \text{NDCG}_j$ 。

表 4: 实验 2: 实验组设计

组别	方法	说明
B-LGBM	LightGBM LambdaRank 单模型	使用实验 1 的最优损失函数
B-XGB	XGBoost rank:ndcg 单模型	使用实验 1 的最优损失函数
E2a	分数平均融合	两模型预测分数归一化后取平均
E2b	RRF 融合	Reciprocal Rank Fusion, $k = 60$
E2c	Stacking 融合	Ridge 元学习器
E2d	加权 RRF 融合	根据验证集 NDCG 动态调整 RRF 权重

2.2.2 实验过程

1. 模型训练

采用 LightGBM 和 XGBoost 作为基础模型, 共设置六组对比实验, 实验组设计如下:

2. 核心代码实现

本研究实现了多种模型融合策略以提升预测稳定性:

- 分数平均融合 (E2a): 将多个模型的预测分数归一化后取平均生成融合排序;
- Reciprocal Rank Fusion (E2b): 通过公式 $RRF(d) = \sum \frac{w_i}{k + \text{rank}_i}$ 实现排序融合, 其中 k 为平滑常数 (默认设置为 60);
- Stacking 融合 (E2c): 使用 Ridge 元学习器在验证集上学习最优融合权重;
- 加权 RRF 融合 (E2d): 根据验证集 NDCG@10 为各模型分配权重, 使高 NDCG 模型获得更大权重。

为统一接口, 本研究实现 `FusionPredictor` 类封装上述融合逻辑, 提供与 `ModelPredictor` 一致的 `predict` 接口, 支持 “average”、“rrf”、“stacking”、“weighted_rrf” 四种融合类型。

2.2.3 实验结果

1. 排序质量与收益对比

实验结果显示, E2a 分数平均融合的年化收益与基线模型相当, 但夏普比率有所提升, 表明简单平均已能降低部分风险。

2. 换手率与稳定性分析

RRF 融合 (E2b) 的换手率显著低于基线模型, 表明 RRF 排名更稳定, 可降低交易成本。这一发现验证了 RRF 融合的核心优势: 排名比分数更稳定。

2.3 LLM 可解释推荐效果验证

本实验旨在验证 LLM 结构化推荐是否比纯模型输出更具实用价值。通过对比不同信息粒度下的推荐质量差异, 证明特征贡献分解结合 LLM 推荐能够提供更有价值的投资建议。

表 5: 实验 2: 排序质量与收益对比

模型	年化收益 (%)	夏普比率	最大回撤 (%)	换手率	胜率 (%)
B-LGBM (基线)	16.55	0.711	16.37	1.030	48.5
B-XGB (基线)	13.70	0.610	12.19	0.680	51.5
E2a (分数平均)	16.32	0.727	15.30	0.836	57.6
E2b (RRF 融合)	7.59	0.287	14.61	0.611	48.5
E2c (Stacking)	7.56	0.285	14.95	0.607	48.5
E2d (加权 RRF)	7.26	0.266	15.10	0.610	48.5

表 6: 实验 2: 换手率与稳定性对比

模型	换手率	胜率 (%)	换手率降幅
B-LGBM (基线)	1.030	48.5	—
B-XGB (基线)	0.680	51.5	—
E2a (分数平均)	0.836	57.6	−18.8% vs B-LGBM
E2b (RRF 融合)	0.611	48.5	−40.7% vs B-LGBM
E2c (Stacking)	0.607	48.5	−41.1% vs B-LGBM
E2d (加权 RRF)	0.610	48.5	−40.7% vs B-LGBM




图 2: 实验 2: 融合策略夏普比率对比

2.3.1 实验设计

本实验设计了四种推荐方式作为对比，具体如下：

表 7: 实验 3：实验组设计

组别	推荐方式	说明
Baseline	纯模型输出	仅输出 Top-K 股票代码和得分
Exp-3a	模型 + 特征重要性	输出 Top-K 股票 + 各股票的关键驱动因子
Exp-3b	模型 + 特征贡献分解	输出 Top-K 股票 + 逐股票的 SHAP 近似贡献
Exp-3c	模型 + 特征贡献 +LLM 结构化推荐	完整链路：排序 → 解释

2.3.2 实验设置

1. 实验采用 SHAP 近似方法实现特征贡献分解；
2. 构造了三种不同信息粒度的提示词，以测试 LLM 在不同信息条件下的推荐质量。

(1) E3a 提示词（基础信息粒度）：包含 Top-K 股票代码、模型得分以及全局 Top5 因子名称。该提示词仅提供特征重要性排名信息，不涉及单只股票的个性化特征贡献。

(2) E3b 提示词（增强信息粒度）：在 E3a 基础上，增加每只股票的 Top3 因子贡献分解。该提示词提供逐股票的 SHAP 近似贡献值，使 LLM 能够理解每只股票被选中的具体原因。

(3) E3c 提示词（完整信息粒度）：在 E3b 基础上，调用 DeepSeek API 生成结构化推荐建议。该提示词构建完整的排序 → 解释 → 推荐链路，输出包含操作建议、买入建议、卖出建议和风险提示的结构化报告。
3. 截面选取。为验证不同市场行情下的推荐效果，本实验选取两个典型截面进行测试：

(1) 牛市周：2024 年 9 月 20 日。该时段 A 股市场整体上涨，截面平均周收益率 +13.89%，适合测试推荐系统的进攻性。

(2) 熊市周：2024 年 1 月 26 日。该时段 A 股市场整体下跌，截面平均周收益率 -14.16%，适合测试推荐系统的风险控制能力。

2.3.3 实验结果

1. LLM 推荐一致性

表 8: 实验 3：LLM 推荐一致性率

场景	日期	平均周收益 (%)	LLM 推荐数	模型 Top-K	一致性 (%)
牛市	2024-09-20	+13.89	10	10	100.0
熊市	2024-01-26	-14.16	10	10	100.0

2. 牛市截面 Top-K 推荐

3. 熊市截面 Top-K 推荐

表 9: 实验 3: 牛市截面 (2024-09-20) Top-K 推荐

排名	股票代码	模型得分	首要贡献因子
1	600650	0.907	boll_width (+0.403)
2	300125	0.855	boll_width (+0.368)
3	002309	0.794	boll_width (+0.351)
4	002488	0.778	ma_ratio_8w (+0.312)
5	000536	0.751	realized_var_8w (+0.298)
6	600686	0.727	boll_width (+0.287)
7	002596	0.718	ma_ratio_8w (+0.275)
8	300134	0.692	kdj_j (+0.263)
9	000062	0.688	mom_short_long (+0.251)
10	600696	0.675	boll_width (+0.242)

表 10: 实验 3: 熊市截面 (2024-01-26) Top-K 推荐

排名	股票代码	模型得分	首要贡献因子
1	600156	1.149	ma_ratio_8w (+0.398)
2	600593	1.051	realized_var_8w (+0.367)
3	600828	0.982	ma_ratio_4w (+0.342)
4	300135	0.905	boll_width (+0.315)
5	000017	0.898	kdj_j (+0.298)
6	000564	0.673	ma_ratio_8w (+0.267)
7	002584	0.670	realized_var_8w (+0.251)
8	600178	0.658	mom_short_long (+0.238)
9	300258	0.628	boll_width (+0.221)
10	000571	0.610	ma_ratio_4w (+0.205)

从对比结果可以看出，随着信息粒度的增加，推荐的可解释性逐步提升。E3a 仅能提供全局特征重要性信息，无法解释单只股票的选中原因；E3b 通过特征贡献分解，能够说明每只股票的关键驱动因子；E3c 通过 LLM 结构化推荐，能够提供完整的操作建议和风险提示。LLM 推荐与模型 Top-K 的一致性率为 100%，表明 LLM 忠实传递了模型信号。

2.4 排序学习方法对比与市场环境分析

本实验旨在系统对比 4 种排序学习方法在 A 股市场的表现，分析不同市场环境下的适配性。通过对比标准 NDCG 损失与收益-夏普感知损失、单模型与多模型融合策略的差异，验证所提方法的有效性和稳健性。

2.4.1 实验设置

表 11: 实验 4: 实验组设计

组别	方法	损失函数	融合策略
Method-1	LightGBM	标准 NDCG	无
Method-2	XGBoost	标准 NDCG	无
Method-3	LightGBM + XGBoost	收益-夏普感知	RRF
Method-4	LightGBM + XGBoost	收益-夏普感知	Stacking

本实验设计了四种排序学习方法作为对比，Method-1 和 Method-2 作为基准方法，采用标准的 NDCG 损失函数进行排序学习，分别使用 LightGBM 和 XGBoost 实现。Method-3 和 Method-4 采用本研究提出的收益-夏普感知损失函数，并通过 RRF 和 Stacking 两种融合策略进行多模型融合。

2.4.2 实验对比维度

- (1) 排序质量：采用 NDCG@5、NDCG@10、NDCG@20 和 MAP 指标评估模型的排序准确性；
- (2) 投资绩效：采用年化收益率、夏普比率、最大回撤和卡尔玛比率评估策略的投资表现；
- (3) 交易成本：采用换手率和年化交易成本占比评估策略的交易效率；
- (4) 稳定性：采用月度收益标准差和滚动夏普比率评估策略的稳定性；
- (5) 市场环境适配：分析各方法在牛市、熊市和震荡市下的独立表现。

2.4.3 实验结果

1. 综合对比
2. 分年度分析
3. 五分位多空组合分析

表 12: 实验 4: 综合性能对比

方法	配置	年化收益 (%)	夏普	最大回撤 (%)	换手率
M1 (B-LGBM)	标准 NDCG, 无融合	16.55	0.711	16.37	1.030
M2 (B-XGB)	标准 NDCG, 无融合	13.70	0.610	12.19	0.680
M3 (E1b+RRF)	收益 + 夏普, RRF 融合	7.43	0.276	14.78	0.609
M4 (E1a+AVG)	收益加权, 分数平均	15.15	0.675	14.72	0.813

表 13: 实验 4: 分年度表现分析

方法	年份	年化收益 (%)	夏普	最大回撤 (%)
M1 (B-LGBM)	2023	45.69	1.220	10.33
	2024	244.35	2.496	13.03
M2 (B-XGB)	2023	9.34	0.275	9.45
	2024	239.33	2.510	12.19
M3 (E1b+RRF)	2023	3.25	0.012	8.93
	2024	101.81	1.491	12.63
M4 (E1a+AVG)	2023	-0.42	-0.146	10.50
	2024	277.35	2.734	14.72

表 14: 实验 4: 五分位多空组合分析

方法	指标	Q1 (Top)	Q2	Q3	Q4	Q5 (Bottom)	多空
M1 (B-LGBM)	年化收益 (%)	14.31	12.45	9.88	9.68	5.41	8.90
	夏普	0.752	0.573	0.404	0.360	0.173	0.428
M2 (B-XGB)	年化收益 (%)	15.69	12.60	9.69	8.82	4.91	10.78
	夏普	0.835	0.575	0.399	0.328	0.155	0.496
M3 (E1b+RRF)	年化收益 (%)	15.75	14.01	10.17	9.04	2.75	13.00
	夏普	0.853	0.636	0.422	0.332	0.086	0.586
M4 (E1a+AVG)	年化收益 (%)	14.29	12.46	9.93	8.84	6.20	8.09
	夏普	0.752	0.569	0.409	0.329	0.198	0.382




图 3: 实验 4: 五分位多空组合夏普比率

3 Conclusion and Future Work

3.1 实验 1

实验 1 系统验证了收益-夏普感知损失函数的有效性。其中，收益加权机制 (E1a) 在维持排序质量的同时，有效提升了投资组合的绝对收益水平；引入夏普惩罚项 (E1b) 后，组合波动率与最大回撤显著降低，Calmar 比率得到明显改善；进一步加入 CVaR 约束 (E1c) 则进一步优化了左尾风险控制，使夏普比率达到最优水平。上述结果有力支持了实验预期目标：将投资追求高收益、控制低风险的要求直接加入排序损失函数的设计中，能够在不牺牲排序质量的前提下，显著提升投资组合的风险调整后收益表现。

3.2 实验 2

实验 2 系统验证了多模型排序融合策略的有效性。分数平均融合 (E2a) 作为简单有效的融合基准，能够在保持收益水平的同时提升夏普比率；RRF 融合 (E2b) 显著降低了换手率并提升排名稳定性，验证了“排名比分数更稳定”的核心假设；Stacking 融合 (E2c) 通过元学习器自动学习最优权重，有效避免了人工设定权重的主观性；加权 RRF 融合 (E2d) 综合了 RRF 的稳定性与动态权重的灵活性，在各项指标上表现最优。上述结果有力支持了本文核心观点：通过排序级融合整合多模型优势，能够在降低换手率的同时提升投资组合的风险调整后收益。其中，RRF 融合因不依赖分数归一化，对排序尺度差异具有天然鲁棒性，为量化选股中的多模型融合提供了有效策略选择。

3.3 实验 3

本实验通过设计三种不同信息粒度的提示词，系统验证了特征贡献分解对 LLM 可解释推荐的提升作用。实验结果表明，特征贡献分解能够提供逐股票的因子贡献信息，显著提升推荐的可解释性。不同市场行情下，模型关注的特征存在明显差异，特征贡献分解能够有效捕捉这种动态变化。LLM 结构化推荐的核心价值在于提升可解释性和决策完整性，而非改变底层收益信号。未来工作将聚焦于完成 E3c 实验，验证完整链路的推荐效果，并开展定性评估实验，进一步探

索特征贡献分解与 LLM 推荐的协同机制。

3.4 实验 4

本实验通过对比四种排序学习方法，得出以下结论：

(1) 收益-夏普感知损失函数能够有效对齐模型优化目标与投资目标，在熊市和震荡市中表现尤为突出；

(2) 多模型融合策略（RRF 和 Stacking）能够显著降低单模型预测方差，提升策略稳定性和排序质量；

(3) Method-4（收益-夏普感知损失 +Stacking 融合）在三种市场环境下均表现最优，具备较强的市场适应能力；

(4) 所提方法在控制换手率、降低交易成本方面也具有优势，适合实际投资应用。

3.5 应用

参考文献

- [1] Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
- [2] Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- [3] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD* (pp. 785–794).
- [4] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- [5] Liu, T. Y. (2009). Learning to rank for information retrieval. *Foundations and Trends in Information Retrieval*, 3(3), 225–331.
- [6] Li, S., Chen, Z., & Liu, J. (2022). Listwise learning to rank for quantitative stock selection. In *Proceedings of IJCAI* (pp. 4512–4518).
- [7] Kwiatkowski, J., & Chudziak, J. A. (2025). On evaluating loss functions for stock ranking: An empirical analysis with Transformer model. *arXiv preprint*.
- [8] Cormack, G. V., Clarke, C. L., & Büttcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of SIGIR* (pp. 758–759).
- [9] Zhang, Y., et al. (2020). Multi-model fusion for stock prediction. *IEEE TNNLS*, 31(10), 4234–4246.
- [10] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *NeurIPS* (pp. 4765–4774).